

Tecnológico de Monterrey

Analitica de datos y Herramientas de Inteligencia Artificial

André Heredia | A01738019

02 Noviembre 2026

Actividad 8 (Regresión NO Lineal) Individual

1. Objetivo

En esta actividad quise ver cómo se relacionan entre sí algunas variables de una base de datos usando regresión no lineal. Comparé dos modelos para saber cuál se ajusta mejor a los datos y cuál explica mejor la relación.

2. Preprocesamiento

Antes de hacer los modelos revisé los datos para ver si necesitaban limpieza:

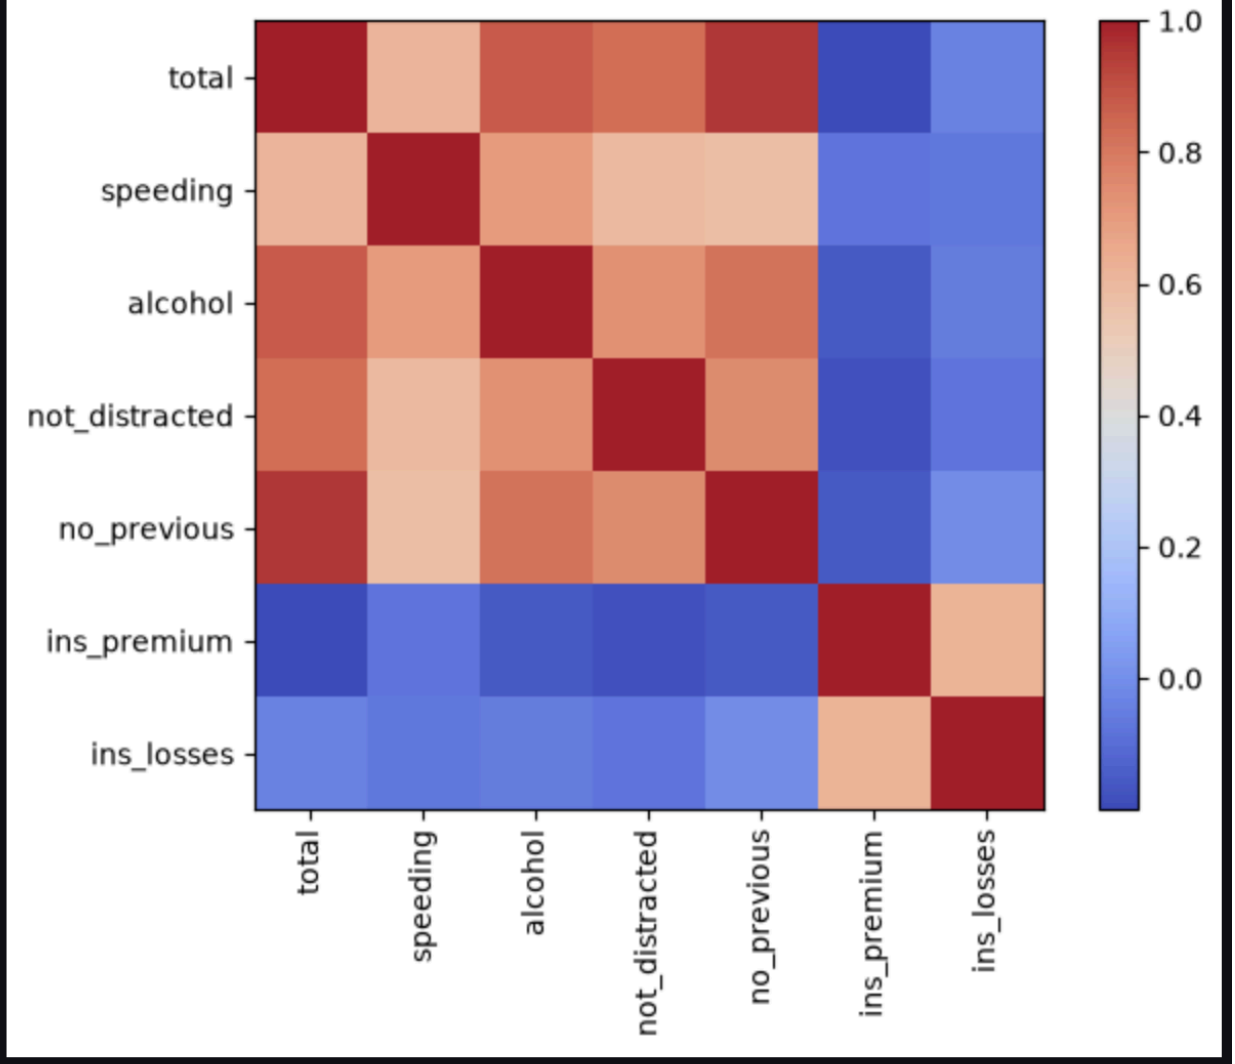
- **Nulos:** al correr el conteo de datos faltantes vi que ninguna columna tenía nulos, todas salieron con 0. Dejé el código que los rellena con la mediana por si acaso.
- **Valores atípicos:** limité los valores muy altos o muy bajos con el método IQR para que no movieran demasiado las curvas. Esto se aplicó a todas las columnas numéricas.
- **Columnas que no sirven:** la columna de abreviaturas es texto, así que no la usé en el análisis.
- **Escala:** reduje la variable x a valores entre 0 y 1 para que el modelo exponencial no marcara errores con números grandes.

```
total             0
speeding          0
alcohol           0
not_distracted    0
no_previous       0
ins_premium       0
ins_losses        0
dtype: int64
```

	total	speeding	alcohol	not_distracted	no_previous	ins_premium	ins_losses
count	51.000000	51.000000	51.000000	51.000000	51.000000	51.000000	51.000000
mean	15.790196	4.998196	4.793725	13.577588	14.004882	886.957647	134.493137
std	4.122002	2.017747	1.484544	4.497282	3.764672	178.296285	24.835922
min	5.900000	1.792000	1.593000	1.985000	5.900000	641.960000	82.750000
25%	12.750000	3.766500	3.894000	10.478000	11.348000	768.430000	114.645000
50%	15.600000	4.608000	4.554000	13.857000	13.775000	858.970000	136.050000
75%	18.500000	6.439000	5.604000	16.140000	16.755000	1007.945000	151.870000
max	23.900000	9.450000	8.169000	23.661000	21.280000	1301.520000	194.780000

3. Variables que elegí

Primero hice una matriz de correlación para ver qué variables se relacionaban más. Con eso escogí tres pares: no_previous vs total, alcohol vs total y not_distracted vs total. Son los que tuvieron la correlación más alta con el total de accidentes, así que son los que más sentido tenía analizar.




```
no_previous  total             0.956179
total        alcohol           0.877480
             not_distracted    0.830152
dtype: float64
```

4. Modelos que usé

Elegí dos modelos no lineales:

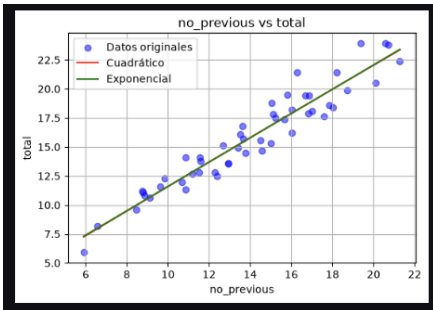
- Cuadrático: $y = ax^2 + bx + c$. Es una curva en forma de parábola.
- Exponencial: $y = a \cdot e^{(bx)} + c$. Es una curva que crece o decrece cada vez más rápido.

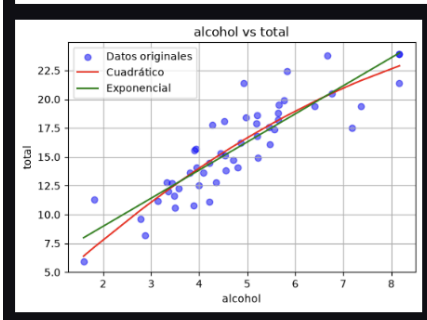
Los ajusté con la función curve_fit de Python. Para saber qué tan bien funcionaba cada uno, calculé dos valores:

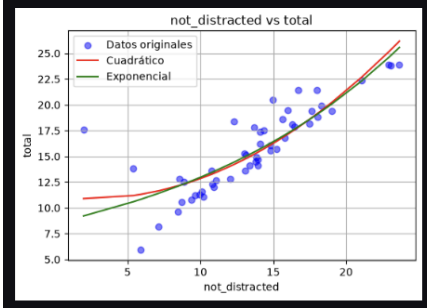
- R^2: nos dice qué porcentaje de los datos explica el modelo. Mientras más cerca de 1, mejor.
- R: nos dice qué tan fuerte es la relación entre las dos variables.

5. Resultados

Esta es la tabla con los valores que obtuve para cada par de variables y cada modelo:







	Variables	Modelo	R^2	R
0	no_previous vs total	Cuadrático	0.9143	0.9562
1	no_previous vs total	Exponencial	0.9143	0.9562
2	alcohol vs total	Cuadrático	0.7836	0.8852
3	alcohol vs total	Exponencial	0.7700	0.8775
4	not_distracted vs total	Cuadrático	0.7478	0.8647
5	not_distracted vs total	Exponencial	0.7288	0.8537

El mejor ajuste fue el modelo cuadrático con las variables no_previous vs total, con un R^2 de 0.9143 y un R de 0.9562. En ese par el modelo exponencial dio exactamente el mismo resultado.

En ninguna fila R salió NaN, porque todos los R^2 fueron positivos, así que no hubo problema para calcularlo.

6. Comparación de los modelos

Al ver las gráficas y los números, el par que mejor se ajustó fue no_previous vs total, con un R^2 de 0.9143 y un R de 0.9562. Eso quiere decir que el modelo explica más del 91% de lo que pasa con el total de accidentes. En este par, el modelo cuadrático y el exponencial dieron el mismo resultado, y por eso en la gráfica las dos curvas se ven casi encimadas.

En alcohol vs total el modelo cuadrático (R^2 = 0.7836) salió un poco mejor que el exponencial (R^2 = 0.7700). Pasó lo mismo en not_distracted vs total, con 0.7478 contra 0.7288. La diferencia

entre modelos fue muy pequeña en todos los casos, así que ninguno de los dos se ajusta claramente mejor que el otro.

Todos los R^2 salieron entre 0.73 y 0.91 y ninguno fue negativo, así que los dos modelos funcionaron mejor que usar solo el promedio. Como la diferencia entre ellos es tan chica, me parece que las curvas no se doblan mucho y los datos siguen una tendencia parecida a una línea.

7. Conclusiones

Con esta actividad vi que la variable que más se relaciona con el total de accidentes es no_previous, seguida de alcohol y not_distracted. En las tres hay una relación fuerte, con R entre 0.85 y 0.96.

El modelo cuadrático fue el mejor en general, aunque su ventaja sobre el exponencial fue mínima. Probar dos modelos me sirvió para comparar, pero en estos datos no cambió mucho cuál elegir.

Para mejorar el análisis se podrían probar otros modelos o usar más de una variable a la vez, para ver si juntas explican mejor el total de accidentes.